

Godzinowy, warunkowany horyzontem model prognozowania PM10, PM2.5, temperatury i opadu

Specyfikacja matematyczna, walidacyjna i wdrożeniowa

Edward Szczypka
edward@szczypka.guru

3 sierpnia 2026

Streszczenie

Dokument opisuje docelowy model systemu Smog AI, w którym prognoza jest wyznaczana dla *dokładnego czasu docelowego*, a nie przez wybór najbliższego z trzech dyskretnych horyzontów 6, 12 i 24 godzin. System prognozuje cztery wielkości:

PM_{10} , $PM_{2.5}$, T , R ,

gdzie T oznacza temperaturę, a R sumę opadu w jawnym okresie akumulacji Δ_R kończącym się w czasie docelowym. Domyślnie $\Delta_R = 6$ godzin, zgodnie z bieżącym kontraktem danych IMGW; system nie tworzy sztucznej dezagregacji na wartości godzinowe. Obliczenia, trening, predykcja i interpolacja przestrzenna są wykonywane lokalnie. DigitalOcean Spaces przechowuje wersjonowane artefakty, a DigitalOcean App Platform wyłącznie odczytuje i prezentuje gotowe wyniki.

Spis treści

1	Cel zmiany	3
2	Notacja	3
3	Dlaczego nie stosujemy globalnego wielomianu przez punkty 6/12/24 h	3
4	Architektura modelu	4
4.1	Model kaskadowy	4
4.2	Cechy czasu docelowego	4
5	Model temperatury	4
6	Dwuetapowy model opadu	5
6.1	Prawdopodobieństwo wystąpienia opadu	5
6.2	Warunkowa wielkość opadu	5
7	Modele PM10 i PM2.5	6
8	Ochrona przed wyciekiem informacji	6
9	Podział chronologiczny i ocena	6
10	Interpolacja czasowa	7

11 Interpolacja przestrzenna	7
12 Niepewność	8
13 Aktywacja modelu	8
14 Artefakty i DigitalOcean Spaces	8
15 Informacja prezentowana użytkownikowi	9
16 Dokumentacja dostępna na platformie	9
17 Wymagania danych	9
18 Konfiguracja referencyjna	9
19 Kryteria odbioru	10

1 Cel zmiany

Dotychczasowe modele były trenowane oddzielnie dla horyzontów

$$h \in \{6, 12, 24\}.$$

Taki model jest poprawny wyłącznie dla czasu

$$u = t + h,$$

gdzie t jest czasem bazowym prognozy. Nie jest poprawne traktowanie modelu $h = 6$ jako prognozy dla $h = 22$ ani ciche wybieranie powierzchni o najbliższym czasie docelowym.

W wersji godzinowej horyzont staje się zmienną objaśniającą:

$$h \in \{1, 2, \dots, H\}, \quad H = 48.$$

Model uczy się zależności pomiędzy stanem układu w chwili t , dokładnym horyzontem h , cechami czasu docelowego $t + h$ oraz wartością prognozowaną.

2 Notacja

Niech:

- $\mathcal{S}_A$ oznacza zbiór stacji jakości powietrza GIOŚ;
- $\mathcal{S}_W$ oznacza zbiór stacji meteorologicznych IMGW;
- $m(s) \in \mathcal{S}_W$ oznacza stację IMGW dopasowaną do stacji $s \in \mathcal{S}_A$;
- t oznacza czas bazowy danych dostępnych przy generowaniu prognozy;
- h oznacza horyzont w godzinach;
- $u = t + h$ oznacza dokładny czas docelowy;
- $P_{s,t}^{10}$ oraz $P_{s,t}^{2.5}$ oznaczają stężenia PM₁₀ i PM_{2.5};
- $T_{m,t}$ oznacza temperaturę;
- $R_{m,t}^{(\Delta_R)}$ oznacza sumę opadu w okresie $[t - \Delta_R, t]$; domyślnie $\Delta_R = 6$ godzin.

Wektor docelowy dla stacji s , czasu bazowego t i horyzontu h ma postać:

$$\mathbf{Y}_{s,t,h} = \begin{bmatrix} P_{s,t+h}^{10} \\ P_{s,t+h}^{2.5} \\ T_{m(s),t+h} \\ R_{m(s),t+h}^{(\Delta_R)} \end{bmatrix}. \quad (1)$$

3 Dlaczego nie stosujemy globalnego wielomianu przez punkty 6/12/24 h

Wielomian drugiego stopnia przechodzący przez trzy punkty

$$(6, \hat{y}_6), \quad (12, \hat{y}_{12}), \quad (24, \hat{y}_{24})$$

jest jednoznacznie wyznaczony, lecz jego gładkość jest wyłącznie własnością algebraiczną. Nie uwzględnia on zmiany temperatury, opadu, wiatru, pory dnia ani emisji. Może więc interpolować gładko, ale fizycznie niewiarygodnie.

Globalny wielomian nie jest modelem prognozowania. W projekcie dopuszczamy interpolację wielomianową wyłącznie na końcowym, lokalnym etapie:

- pomiędzy dwiema lub kilkoma *już wyznaczonymi prognozami godzinowymi*;
- bez ekstrapolacji poza zakres dostępnych prognoz;
- z jawnym oznaczeniem metody.


Domyślną metodą dla czasu niecałkowitego jest PCHIP, czyli przedziałowy wielomian Hermite'a zachowujący lokalny kształt. Dla zapytania o pełną godzinę interpolacja czasowa nie jest potrzebna.

4 Architektura modelu

4.1 Model kaskadowy

Ze względu na różny charakter zmiennych nie stosujemy jednej wspólnej funkcji straty dla wszystkich czterech wyjść. Domyślną architekturą jest kaskada:

1. model temperatury;
2. dwuetapowy model opadu;
3. modele PM_{10} i $\text{PM}_{2.5}$, które korzystają z prognozowanej temperatury i prognozowanego opadu dla czasu docelowego.



Rysunek 1: Kaskadowa architektura modelu godzinowego.

4.2 Cechy czasu docelowego

Czas docelowy $u = t + h$ jest kodowany cyklicznie:

$$\phi_{\text{hour},1}(u) = \sin\left(2\pi \frac{\text{hour}(u)}{24}\right), \quad (2)$$

$$\phi_{\text{hour},2}(u) = \cos\left(2\pi \frac{\text{hour}(u)}{24}\right), \quad (3)$$

$$\phi_{\text{dow},1}(u) = \sin\left(2\pi \frac{\text{dow}(u)}{7}\right), \quad (4)$$

$$\phi_{\text{dow},2}(u) = \cos\left(2\pi \frac{\text{dow}(u)}{7}\right), \quad (5)$$

$$\phi_{\text{year},1}(u) = \sin\left(2\pi \frac{\text{doy}(u)}{365.2425}\right), \quad (6)$$

$$\phi_{\text{year},2}(u) = \cos\left(2\pi \frac{\text{doy}(u)}{365.2425}\right). \quad (7)$$

Horyzont h jest wprowadzany jawnie oraz opcjonalnie przez bazę funkcji:

$$1, \quad h, \quad h^2, \quad \log(1+h), \quad \sqrt{h}.$$

Nie oznacza to globalnej regresji wielomianowej po wyniku. Są to jedynie cechy, z których nieliniowy model może skorzystać, jeżeli poprawiają walidację.

5 Model temperatury

Model temperatury ma postać:

$$\hat{T}_{s,t,h} = f_T\left(\mathbf{X}_{m(s),t}^{\text{weather}}, h, \phi(t+h), z_{m(s)}, \text{lat}_{m(s)}, \text{lon}_{m(s)}\right). \quad (8)$$

Wektor $\mathbf{X}^{\text{weather}}$ zawiera między innymi:

$$T_{t-1}, T_{t-3}, T_{t-6}, T_{t-12}, T_{t-24},$$

średnie kroczące, trend temperatury, wilgotność, ciśnienie, wiatr i opad.

Domyślnym estymatorem jest histogramowy gradient boosting. Modele bazowe:

$$\hat{T}_{t+h}^{\text{pers}} = T_t, \quad (9)$$

$$\hat{T}_{t+h}^{\text{season}} = \text{median}\{T_\tau : \text{hour}(\tau) = \text{hour}(t+h), \text{month}(\tau) = \text{month}(t+h)\}. \quad (10)$$

Dla estymacji punktowej stosujemy MAE lub stratę kwadratową, a dla przedziałów predykcji osobne modele kwantylowe:

$$\rho_\tau(e) = \begin{cases} \tau e, & e \geq 0, \\ (\tau - 1)e, & e < 0. \end{cases} \quad (11)$$

6 Dwuetapowy model opadu

Opad ma rozkład z dużą masą w zerze i silną prawostronną asymetrią. Dlatego stosujemy model typu *hurdle*.

Niech $\delta \geq 0$ będzie progiem mierzalnego opadu, np. $\delta = 0.1$ mm. Definiujemy:

$$Z_{s,t,h} = \mathbf{1}\{R_{m(s),t+h}^{(\Delta_R)} > \delta\}. \quad (12)$$

6.1 Prawdopodobieństwo wystąpienia opadu

$$\hat{\pi}_{s,t,h} = \mathbb{P}(Z_{s,t,h} = 1 \mid \mathbf{X}_{s,t}, h, \phi(t+h)) = \sigma(f_\pi(\mathbf{X}_{s,t}, h, \phi(t+h))), \quad (13)$$

gdzie σ oznacza funkcję logistyczną. Strata:

$$\mathcal{L}_{\text{occ}} = - \sum_i [z_i \log \hat{\pi}_i + (1 - z_i) \log(1 - \hat{\pi}_i)]. \quad (14)$$

6.2 Warunkowa wielkość opadu

Dla obserwacji dodatnich:

$$A_{s,t,h} = R_{m(s),t+h}^{(\Delta_R)} \mid Z_{s,t,h} = 1. \quad (15)$$

Modelujemy $\mathbb{E}[A \mid Z = 1, \mathbf{X}, h]$ regresją dodatnią, np. z funkcją łączącą logarytmiczną lub przez transformację $\log(1 + A)$. Prognoza średniego opadu:

$$\hat{R}_{s,t,h} = \hat{\pi}_{s,t,h} \hat{\mu}_{A,s,t,h}. \quad (16)$$

Oprócz wartości oczekiwanej aplikacja pokazuje:

$$\hat{\pi}_{s,t,h}, \quad \hat{\mu}_{A,s,t,h}, \quad \hat{R}_{s,t,h}.$$

Semantyka okresu akumulacji. Wartość $\hat{R}_{s,t,h}$ nie oznacza natężenia w mm/h, lecz akumulację w przedziale długości Δ_R kończącym się w $t+h$. Okres jest częścią kontraktu modelu, artefaktu i odpowiedzi API. Zmiana źródła danych może ustawić $\Delta_R = 1$ godzinę, ale nie wolno bezpośrednio dzielić pomiaru sześciogodzinnego przez sześć. Dzięki temu wartość 0.4 mm nie jest mylnie interpretowana jako pewny, ciągły opad.

7 Modele PM10 i PM2.5

Dla $k \in \{10, 2.5\}$:

$$\hat{P}_{s,t,h}^k = f_k(\mathbf{X}_{s,t}^{\text{air}}, \mathbf{X}_{m(s),t}^{\text{weather}}, h, \phi(t+h), \hat{T}_{s,t,h}, \hat{R}_{s,t,h}, \hat{\pi}_{s,t,h}, \text{lat}_s, \text{lon}_s). \quad (17)$$

Cechy jakości powietrza obejmują opóźnienia, średnie kroczące, tempo zmian oraz informacje z pobliskich stacji. Prognozowana temperatura i opad są cechami czasu docelowego, a nie obserwacjami pobranymi z przyszłości.

8 Ochrona przed wyciekami informacji

Najważniejszym niezmiennikiem jest:

każda cecha użyta w prognozie utworzonej w chwili t musi być dostępna w chwili t .

Nie wolno trenować modelu PM na rzeczywistej temperaturze z chwili $t+h$, jeżeli w produkcji dostępna będzie tylko jej prognoza. Zastosowana zostanie chronologiczna predykcja krzyżowa:

1. dzielimy czasy bazowe na uporządkowane bloki $I_1 < I_2 < \dots < I_K$;
2. dla bloku I_j model pogodowy jest trenowany wyłącznie na blokach wcześniejszych;
3. generujemy prognozy $\tilde{T}_i, \tilde{R}_i, \tilde{\pi}_i$ dla $i \in I_j$;
4. modele PM są trenowane na tych prognozach, nie na rzeczywistej pogodzie z przyszłości.

Formalnie:

$$\tilde{T}_i = f_T^{(-j)}(\mathbf{X}_i, h_i), \quad i \in I_j, \quad (18)$$

gdzie $f_T^{(-j)}$ nie widziało żadnej obserwacji z bloku I_j ani z bloków późniejszych.

9 Podział chronologiczny i ocena

Nie stosujemy losowego podziału. Używamy walidacji typu rolling origin lub expanding window:

$$\underbrace{[1, \dots, t_1]}_{\text{trening}} \rightarrow \underbrace{[t_1 + 1, \dots, t_2]}_{\text{walidacja}},$$

następnie powiększamy zbiór treningowy.

Metryki są obliczane:

- osobno dla każdej zmiennej;
- osobno dla każdego horyzontu $h = 1, \dots, 48$;
- według stacji, pory dnia, sezonu i warunków pogodowych;
- łącznie i względem modelu bazowego.

Dla temperatury i PM:

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (19)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (20)$$

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}. \quad (21)$$

Dla opadu:

- Brier score i ROC-AUC dla wystąpienia opadu;
- MAE/RMSE dla dodatniej wielkości opadu;
- MAE i Tweedie deviance dla całkowitej prognozy opadu;
- trafność progów, np. $R > 1$ mm.

10 Interpolacja czasowa

Model generuje prognozy dla każdej pełnej godziny:

$$h = 1, 2, \dots, 48.$$

Dla zapytania o pełną godzinę wybór jest dokładny:

$$\hat{y}(u) = \hat{y}_h, \quad u = t + h.$$

Dla zapytania np. o 17:30 dopuszczamy interpolację pomiędzy prognozami 17:00 i 18:00. Domyślnie:

- interpolacja liniowa przy dwóch sąsiednich punktach;
- PCHIP przy wystarczającej liczbie sąsiednich prognoz;
- brak ekstrapolacji poza $[t + 1, t + 48]$.

API zwraca:

```
{
  "requested_target_time": "...",
  "selected_target_time": "...",
  "forecast_origin_time": "...",
  "horizon_hours": 22.0,
  "exact_time_match": true,
  "temporal_method": "direct_hourly_model"
}
```

11 Interpolacja przestrzenna

Dla ustalonego czasu docelowego u i zmiennej y otrzymujemy prognozy punktowe $\hat{y}_i(u)$ dla stacji $i = 1, \dots, n$. W wariancie IDW:

$$w_i(x) = \frac{1}{(d(x, x_i) + \varepsilon)^p}, \quad (22)$$

$$\hat{y}(x, u) = \frac{\sum_{i \in \mathcal{N}_k(x)} w_i(x) \hat{y}_i(u)}{\sum_{i \in \mathcal{N}_k(x)} w_i(x)}. \quad (23)$$

Dla opadu interpolujemy oddzielnie:

$$\hat{\pi}(x, u) \quad \text{oraz} \quad \hat{\mu}_A(x, u),$$

a następnie:

$$\hat{R}(x, u) = \hat{\pi}(x, u) \hat{\mu}_A(x, u).$$

Ogranicza to sztuczne rozsmarowywanie niewielkiego opadu na cały kraj.

Dla temperatury możliwa jest opcjonalna korekta wysokościowa:

$$\hat{T}_i^*(u; x) = \hat{T}_i(u) + \gamma(z_i - z(x)), \quad (24)$$

gdzie γ jest estymowany na danych walidacyjnych, a nie przyjmowany bezkrytycznie jako stały gradient atmosferyczny.

12 Niepewność

Dla każdej zmiennej przewidujemy kwantyle, np.

$$q_{0.10}(x, u), \quad q_{0.50}(x, u), \quad q_{0.90}(x, u).$$

Przedział 80%:

$$I_{0.8}(x, u) = [q_{0.10}(x, u), q_{0.90}(x, u)].$$

Warstwa przestrzenna dodaje niepewność wynikającą z odległości od stacji, liczby sąsiadów i walidacji leave-one-station-out. W uproszczonym wariancie:

$$\sigma_{\text{total}}^2(x, u) = \sigma_{\text{model}}^2(x, u) + \sigma_{\text{spatial}}^2(x, u). \quad (25)$$

13 Aktywacja modelu

Model nie jest aktywowany tylko dlatego, że został wytrenowany. Dla każdej zmiennej porównujemy go z modelem bazowym. Przykładowy warunek:

$$\frac{\text{MAE}_{\text{base}} - \text{MAE}_{\text{candidate}}}{\text{MAE}_{\text{base}}} \geq \eta, \quad (26)$$

gdzie η jest minimalną wymaganą poprawą.

Dodatkowe warunki:

- brak regresji jakości dla krytycznych horyzontów;
- poprawne pokrycie przedziałów kwantylowych;
- brak niefizycznych wartości;
- zgodność schematu cech i wersji danych;
- przejście testu predykcji kontrolnej.

14 Artefakty i DigitalOcean Spaces

Wyniki są indeksowane przez dokładny czas:

```
hourly/
models/
  temperature/active.json
  precipitation/active.json
  PM10/active.json
  PM2.5/active.json
forecasts/
  origin=2026-08-03T10-00-00Z/
    target=2026-08-03T11-00-00Z/
    ...
    target=2026-08-05T10-00-00Z/
maps/
  origin=.../
    target=.../
      PM10/surface.json.gz
      PM2.5/surface.json.gz
      temperature_c/surface.json.gz
      precipitation_probability/surface.json.gz
      precipitation_mm/surface.json.gz
```

App Platform nie wykonuje modelu. Odczytuje dokładny pakiet dla `target_time`. Jeżeli pakiet nie istnieje, zwraca informację o braku prognozy; nie wybiera po cichu najbliższego czasu.

15 Informacja prezentowana użytkownikowi

Dla każdego wyniku interfejs pokazuje:

- czas bazowy;
- dokładny czas docelowy;
- horyzont w godzinach;
- metodę prognozy;
- wersję każdego modelu;
- PM10, PM2.5, temperaturę i opad;
- prawdopodobieństwo opadu;
- przedziały niepewności;
- współrzędne punktu zapytania;
- współrzędne środka komórki siatki;
- odległość pomiędzy punktami;
- algorytm interpolacji przestrzennej i liczbę stacji.

16 Dokumentacja dostępna na platformie

Platforma udostępnia:

- zakładkę *Model matematyczny*;
- zakładkę *Jak działa przetwarzanie*;
- endpoint GET `/api/v1/docs/mathematics`;
- endpoint GET `/api/v1/docs/processing`;
- pobranie źródła $\text{\LaTeX}$;
- opcjonalne pobranie skompilowanego PDF.

17 Wymagania danych

Bieżący endpoint SYNOP daje najnowszą obserwację, co nie wystarcza do trenowania modeli pogodowych. Pipeline powinien automatycznie uzupełnić historię z oficjalnych, miesięcznych archiwów terminowych IMGW. Minimalny praktyczny zakres pilota:

- co najmniej 3–6 miesięcy danych godzinowych dla testu technicznego;
- pełny rok dla uchwycenia sezonowości;
- preferowane 2–3 lata dla stabilniejszej walidacji.

Jeżeli historia jest niewystarczająca, system nie może udawać modelu produkcyjnego. Powinien aktywować jawny fallback i wyświetlać status `insufficient_history`.

18 Konfiguracja referencyjna

```
hourly_forecasting:
  enabled: true
  min_horizon_hours: 1
  max_horizon_hours: 48
  step_hours: 1
  exact_target_time_required: true
  temporal_interpolation: pchip
  allow_extrapolation: false
  targets:
    - PM10
    - PM2.5
    - temperature_c
    - precipitation_mm
  precipitation:
```

```
occurrence_threshold_mm: 0.1
model: hurdle
uncertainty:
  quantiles: [0.10, 0.50, 0.90]
validation:
  strategy: expanding_window
  cross_fit_weather_for_pm: true
  minimum_folds: 3
```

19 Kryteria odbioru

Zmiana jest ukończona, gdy:

1. prognozy istnieją dla każdej godziny $1, \dots, 48$;
2. temperatura i opad są pełnoprawnymi celami;
3. zapytanie o godzinę nie wybiera najbliższego modelu 6/12/24;
4. modele PM korzystają z prognoz pogodowych uzyskanych bez wycieku;
5. PCHIP jest używany wyłącznie pomiędzy sąsiednimi godzinami;
6. opad ma osobny model wystąpienia i wielkości;
7. metryki są liczone dla każdej zmiennej i każdego horyzontu;
8. powierzchnie mapy są wersjonowane przez `target_time`;
9. API i UI pokazują czas bazowy, docelowy oraz metodę;
10. dokument matematyczny jest dostępny w aplikacji i jako plik $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$.

Literatura

- [1] Scikit-learn developers, *HistGradientBoostingRegressor — official documentation*. Dokumentacja opisuje m.in. straty Poissona, gamma oraz kwantylową.
- [2] Scikit-learn developers, *TweedieRegressor — official documentation*. Uogólniony model liniowy z rozkładem Tweediego.
- [3] Scikit-learn developers, *TimeSeriesSplit — official documentation*. Chronologiczna walidacja bez trenowania na przyszłości.
- [4] SciPy developers, *PchipInterpolator — official documentation*. Przedziałowa interpolacja Hermite’a zachowująca lokalny kształt.
- [5] IMGW-PIB, *Dane pomiarowo-obszerwacyjne: terminowe dane synoptyczne*. Oficjalne miesięczne archiwa danych meteorologicznych.