

Smog AI 1.7.0

Dokumentacja techniczna przetwarzania danych, treningu, predykcji i publikacji

Edward Szczypka
edward@szczypka.guru

3 sierpnia 2026

Streszczenie

Dokument opisuje kompletny przepływ systemu Smog AI: od pobrania danych GIOŚ oraz IMGW, przez lokalną bazę SQLite, walidację Pandera, przygotowanie wersjonowanych zbiorów uczących, otwartą platformę modeli, prognozy godzinowe na 1–48 godzin, przestrzenną interpolację Polski i publikację do DigitalOcean Spaces, aż do publicznego FastAPI i dashboardu Streamlit. Dokument jest techniczny: wskazuje kontrakty danych, kolejność etapów, niezmienniki, idempotencję, punkty rozszerzeń, obsługę błędów i procedury operacyjne. Specyfikacja matematyczna modeli znajduje się w odrębnym dokumencie `DOKUMENTACJA_MODELU_GODZINOWEGO_PL.tex`.

Spis treści

1	Granice systemu	3
1.1	Komputer lokalny	3
1.2	DigitalOcean	3
2	Diagram przepływu	3
3	Konfiguracja i przenośność	3
4	Pobieranie GIOŚ	4
5	Pobieranie IMGW	4
5.1	Dane bieżące	4
5.2	Oficjalne archiwum terminowe/SYNOP	4
6	Lokalna baza SQLite	5
7	Walidacja Pandera	5
8	Warstwy Bronze, Curated i Serving	5
8.1	Bronze	5
8.2	Curated	5
8.3	Serving	6
9	Przygotowanie cech	6
10	Otwarta platforma modeli	6
11	Kolejność treningu	6

12 Prognoza godzinowa	7
13 Interpolacja przestrzenna	7
14 Publikacja do Spaces	7
15 FastAPI	7
16 Dashboard	8
17 Idempotencja i odporność	8
18 Harmonogram Windows	8
19 Backup i odzyskiwanie	8
20 Monitoring i diagnostyka	9
21 Kontrakty odbioru	9
22 Polecenia operacyjne	9
23 Dokumenty powiązane	10

1 Granice systemu

System składa się z dwóch niezależnych komponentów.

1.1 Komputer lokalny

Komputer lokalny odpowiada za wszystkie operacje obliczeniowe:


- pobieranie danych GIOŚ i IMGW;
- historię pomiarów w SQLite;
- walidację, kontrolę jakości i dopasowanie stacji;
- publikację pakietu wejściowego do Spaces;
- ponowne pobranie pakietu ze Spaces do treningu;
- przygotowanie cech, trening i wybór modeli;
- prognozy punktowe dla dokładnych godzin;
- interpolację przestrzenną całej Polski;
- publikację modeli, metryk, prognoz, map i dokumentacji.

1.2 DigitalOcean

DigitalOcean Spaces jest prywatnym magazynem obiektowym zgodnym z S3. DigitalOcean App Platform uruchamia FastAPI i Streamlit. Warstwa zdalna:

- nie pobiera danych źródłowych;
- nie trenuje modeli;
- nie uruchamia `model.predict()`;
- nie interpoluje przestrzennie;
- odczytuje wyłącznie gotowe, lokalnie policzone artefakty.

2 Diagram przepływu



Rysunek 1: Przepływ end-to-end. Strzałka Spaces → lokalny trening jest celowa i realizuje wymaganie komunikacji z Cloud Storage.

3 Konfiguracja i przenośność

Projekt nie ma zaszytego katalogu instalacji. Katalog repozytorium jest ustalany na podstawie położenia skryptu albo przez `SMOG_AI_PROJECT_ROOT`. Dane uruchomieniowe są przechowywane poza repozytorium, domyślnie w `%ProgramData%\SmogAI`.

Główne pliki:

```
C:\ProgramData\SmogAI\config.yaml
C:\ProgramData\SmogAI\smog-ai.env
C:\ProgramData\SmogAI\server-local.env
C:\ProgramData\SmogAI\data\smog.db
C:\ProgramData\SmogAI\logs\...
C:\ProgramData\SmogAI\models\...
```

Sekrety nie są przekazywane w argumentach procesu. Plik środowiskowy jest ładowany jawnie przez skrypty PowerShell i nie trafia do Git.

4 Pobieranie GIOŚ

Klient GIOŚ:

1. pobiera listę stacji stronicowanym endpointem JSON-LD;
2. pobiera sensory każdej stacji;
3. wybiera PM10 i PM2.5;
4. pobiera bieżącą serię stanowiska;
5. normalizuje daty do UTC;
6. zapisuje odpowiedź diagnostyczną w `raw_json`;
7. wstawia rekordy idempotentnie przez ograniczenie UNIQUE.

Błąd pojedynczego sensora nie unieważnia całej kolekcji. Niedostępne endpointy stanowisk historycznych są klasyfikowane jako pominięte lub ostrzeżenia, a rzeczywiste błędy sieciowe trafiają do `collection_errors`.

5 Pobieranie IMGW

5.1 Dane bieżące

Endpoint SYNOP dostarcza najnowsze obserwacje stacji. Wartość opadu jest zapisywana z jawnym polem `precipitation_accumulation_period_hours`. Domyślna konfiguracja traktuje ją jako akumulację sześciogodzinną kończącą się w czasie pomiaru. System nie dzieli takiej wartości przez sześć i nie tworzy sztucznego rozkładu godzinowego.

5.2 Oficjalne archiwum terminowe/SYNOP

Adapter archiwalny:

1. wyznacza miesiące objęte skonfigurowanym lookbackiem;
2. odczytuje listing rocznego katalogu IMGW;
3. pobiera miesięczne ZIP-y do lokalnego cache;
4. liczy SHA-256 i sprawdza integralność ZIP;
5. czyta CSV według dołączonego oficjalnego nagłówka;
6. normalizuje stację i czas;
7. zapisuje temperaturę, wilgotność, ciśnienie, wiatr i opad;

8. zachowuje kody jakości oraz pochodzenie w `raw_json`;
9. zapisuje checksum przetworzonego pliku w `application_state`.

Ponowne uruchomienie pomija plik, którego checksum i status sukcesu nie uległy zmianie. Kody pól archiwum są konfigurowalne, dzięki czemu adapter można zastąpić lub dostosować bez zmiany domeny.

6 Lokalna baza SQLite

Baza pracuje w trybie WAL z ustawionym `busy_timeout`. Migracje są prowadzone przez Alembic. Najważniejsze niezmienniki:

- pomiar jest unikalny według źródła, sensora/stacji, parametru i czasu;
- prognoza jest unikalna według modelu, stacji, parametru, czasu utworzenia, czasu docelowego i horyzontu;
- prognoza jest zapisywana przed czasem docelowym;
- nie usuwa się podejrzanych pomiarów — otrzymują flagi jakości.

7 Walidacja Pandera

Każdy etap ma osobny kontrakt:

- pomiary GIOŚ;
- pomiary IMGW;
- pakiet operacyjny;
- godzinowe ramki treningowe;
- prognozy;
- snapshot i powierzchnie przestrzenne.

Raport zawiera czas rozpoczęcia i zakończenia, liczbę wierszy, kolumny, przypadki błędów i checksum. Polityki `report` oraz `fail` są konfigurowalne. Błąd kontraktu treningowego zatrzymuje aktywację modelu.

8 Warstwy Bronze, Curated i Serving

8.1 Bronze

Pakiet `operational-data.json.gz` zawiera stacje, sensory, pomiary i dopasowania. Manifest ma `run_id`, zakres danych, licznosci, checksum, status kompletności i listę brakujących elementów.

8.2 Curated

Dla każdego celu tworzony jest wersjonowany zbiór godzinowy. Rekord zawiera:

```
measurement_time # origin_time
target_time
horizon_hours
station/source identifiers
lags and rolling features
target-time cyclic features
target
```

Warunek czasu jest walidowany:

$$\text{target_time} - \text{measurement_time} = \text{horizon_hours}.$$

8.3 Serving

Serving zawiera gotowe prognozy stacyjne, powierzchnie mapowe, model cards, metryki i dokumentację. App Platform korzysta tylko z tej warstwy.

9 Przygotowanie cech

Cechy są obliczane wyłącznie z danych dostępnych w chwili bazowej. Obejmują:

- lagi 1, 3, 6, 12 i 24 godziny;
- średnie i odchylenia kroczące;
- tempo zmian;
- składowe kierunku wiatru;
- współrzędne i identyfikatory stacji;
- dokładny horyzont 1–48 godzin;
- sinus/cosinus godziny, dnia tygodnia i roku czasu docelowego.

Opad pozostaje wielkością dla jawnego okresu akumulacji. Jeżeli źródło ma okres 6 h, cecha i cel oznaczają akumulację 6 h kończącą się w `target_time`; jednostka prezentacyjna brzmi `mm / 6 h`.

10 Otwarta platforma modeli

Domena używa Bridge `ModelProvider`. Provider implementuje:

```
class ModelProvider(Protocol):
    name: str
    task: ModelTask

    def fit(self, X, y, *, context): ...
    def predict(self, artifact, X, *, context) -> PredictionBundle: ...
    def describe(self, artifact) -> dict: ...
```

Provider nie otrzymuje sesji SQLAlchemy, klienta Spaces, FastAPI ani Streamlit. Może pochodzić z:

- rejestru metod wbudowanych;
- modułu z `register_models(registry)`;
- entry pointu `smog_ai.model_providers`;
- import stringu `module:object`.

W ten sposób można dołączyć Huber, GAM, splajny, XGBoost, LightGBM, CatBoost, PyTorch, model grafowy lub własny model bez przebudowy pipeline'u.

11 Kolejność treningu

Trening przebiega kaskadowo:

1. model temperatury;
2. model opadu typu hurdle;
3. chronologiczne prognozy out-of-fold temperatury i opadu;
4. dołączenie prognoz pogody jako cech PM;
5. trening PM10 i PM2.5;
6. porównanie kandydatów z modelami bazowymi;
7. zapis niezmiennego artefaktu i model card;

8. atomowa aktualizacja aktywnego wskaźnika.

Cross-fitting chronologiczny zapobiega przekazaniu modelowi PM rzeczywistej pogody z przyszłości. Przy niedostatecznej historii aktywowany jest jawny fallback `insufficient_history`.

12 Prognoza godzinowa

Dla wspólnego `origin_time` system tworzy wiersze dla $h = 1, \dots, 48$. Dla każdego wiersza:

$$\text{target_time} = \text{origin_time} + h.$$

Nie istnieje logika wybierania najbliższego spośród 6/12/24 godzin. Dla pełnej godziny wynik pochodzi z bezpośredniego modelu warunkowanego horyzontem. Dla czasu pomiędzy pełnymi godzinami można zastosować interpolację liniową lub PCHIP wyłącznie pomiędzy sąsiednimi prognozami. Ekstrapolacja jest domyślnie zabroniona.

13 Interpolacja przestrzenna

Dla każdej zmiennej i każdego `target_time` powstaje osobna powierzchnia. Interpolator jest kolejnym wymiennym Bridge:

- IDW — metoda domyślna;
- RBF — alternatywa;
- kolejne implementacje mogą dodać kriging lub model grafowy.

Na mapie odróżniane są:

- dokładne współrzędne miasta;
- środek wybranej komórki siatki;
- stacje użyte do interpolacji;
- odległość do najbliższej stacji;
- miara pewności przestrzennej.

14 Publikacja do Spaces

Obiekty są zapisywane najpierw pod niezmiennym kluczem wersji. Dopiero po udanym uploadzie i sprawdzeniu checksum aktualizowany jest mały wskaźnik `latest.json`. Dzięki temu App Platform nigdy nie zobaczy częściowo zapisanego pakietu.

Przykładowe prefiksy:

```
datasets/bronze/  
datasets/curated-hourly/  
models-hourly/  
metrics/hourly-models/  
forecasts/  
maps/  
documentation/
```

15 FastAPI

FastAPI uruchamiane na App Platform:

- interpretuje pytanie tekstowe do struktury;
- rozwiązuje nazwę miejsca;
- wybiera pakiet o dokładnym `target_time`;
- odczytuje wartość z gotowej powierzchni;
- zwraca dokładny punkt, model, jednostkę i niepewność;

- udostępnia dokumentację techniczną i matematyczną.

Brak pakietu dla czasu docelowego daje jawną odpowiedź o braku prognozy. Serwer nie wybiera potajemnie najbliższej godziny.

16 Dashboard

Dashboard prezentuje:

- mapę 2D jako tryb domyślny;
- opcjonalne, ograniczone logarytmicznie 3D;
- nazwy miast jako warstwę nad kolumnami;
- PM10, PM2.5, temperaturę, prawdopodobieństwo i sumę opadu;
- dokładny punkt zapytania i środek komórki;
- profil godzinowy;
- modele, metryki i providerów;
- dokumentację Markdown i źródła LaTeX.

17 Idempotencja i odporność

Każdy etap może zostać powtórzony. Idempotencję zapewniają:

- ograniczenia UNIQUE w SQLite;
- checksum archiwów i artefaktów;
- niezmiennie klucze wersji;
- deterministyczne identyfikatory publikacji;
- outbox z ponowieniami i exponential backoff;
- aplikacyjna dzierżawa oraz mutex Windows;
- atomowe wskaźniki aktywnych modeli i powierzchni.

18 Harmonogram Windows

Zadanie	Zakres
Godzinowe	GIOŚ, bieżące IMGW, walidacja, dopasowanie, weryfikacja, prognozy, powierzchnie, snapshot i publikacja.
Dzienne	Uzupełnianie historii, oficjalne archiwum IMGW, raport jakości, outbox, czyszczenie i backup dzienny.
Tygodniowe	Cloud round-trip, ramki uczące, trening, walidacja, aktywacja, prognozy i publikacja model cards.
Miesięczne	Integralność SQLite, backup miesięczny, retencja i raport miejsca.

Każde zadanie używa pełnych ścieżek, interpretera z `.venv`, blokady, limitu czasu, logu oraz propaguje kod zakończenia.

19 Backup i odzyskiwanie

SQLite jest kopiowana przez Online Backup API, a nie przez bezpośrednie kopiowanie aktywnego pliku WAL. Backup zawiera SHA-256, rozmiar i wynik `PRAGMA quick_check`. Procedura odzyskiwania:

1. zatrzymać zadania i procesy API;
2. zabezpieczyć pliki bazy, WAL i SHM;

3. sprawdzić backup;
4. odtworzyć bazę albo uruchomić migracje do pustej bazy;
5. ponownie uruchomić kolekcję idempotentną;
6. sprawdzić Spaces i healthcheck.

20 Monitoring i diagnostyka

Healthcheck kontroluje bazę, integralność, ostatnią kolekcję, prognozę, publikację, outbox, modele, wolne miejsce, Spaces i stan zadań. Logi JSON zawierają czas, poziom, logger, etap i wyjątek. Raporty Pandera i model cards są publikowane jako niezależne artefakty audytowe.

21 Kontrakty odbioru

Wersja jest technicznie ukończona, gdy:

1. migracje przechodzą na pustej i istniejącej bazie;
2. importer GIOŚ i oba adaptory IMGW są idempotentne;
3. pakiet Bronze jest kompletny i zwalidowany;
4. trening rzeczywiście odczytuje dane ze Spaces;
5. rejestr wykrywa metody wbudowane i pluginy;
6. prognozy istnieją dla godzin 1–48;
7. każda prognoza ma dokładny czas bazowy i docelowy;
8. opad ma jawny okres akumulacji;
9. powierzchnie istnieją dla wszystkich skonfigurowanych celów;
10. FastAPI nie wykonuje modelu ani interpolacji;
11. dashboard pokazuje dokładny punkt, modele i dokumentację;
12. testy, release gate, wheel i ponowne rozpakowanie ZIP przechodzą.

22 Polecenia operacyjne

```
python -m smog_ai backfill-imgw-archive
python -m smog_ai upload-operational-data
python -m smog_ai build-hourly-features --source object_store
python -m smog_ai list-model-methods
python -m smog_ai train-hourly
python -m smog_ai predict-hourly
python -m smog_ai publish-documentation
python -m smog_ai storage-health
python -m smog_ai hourly-readiness
python -m smog_ai healthcheck --json
```

23 Dokumenty powiązane

- `DOKUMENTACJA_MODELU_GODZINOWEGO_PL.tex` — model matematyczny;
- `TECHNICAL_PROCESSING_PL.md` — wersja platformowa;
- `MODEL_PLUGIN_GUIDE_PL.md` — tworzenie providerów;
- `CUSTOM_MODEL_PROVIDER_PL.md` — kompletny przykład pluginu.